НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ ІМЕНІ ІГОРЯ СІКОРСЬКОГО»

Дослідження і проектування інтелектуальних систем

12 жовтня 2026 р.

Штучний інтелект

Будь-яка техніка, яка дозволяє комп'ютерам імітувати поведінку людини



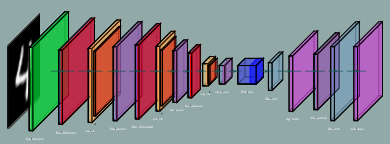
Машинне навчання

Можливість комп'ютера учитися не будучи явно запрограмованим



Глибинне навчання

Пошук шаблону в даних за допомогою нейронних мереж



ПР 3: Увага та трансформери

«Кожен аспект навчання або будь-яка риса інтелекту може бути описана настільки точно, що її можна відтворити у машині.»

– Джон Маккарті, автор терміна «штучний інтелект»

Вступ

Одним з найважливіших досягнень сучасного штучного інтелекту є поява моделей на основі **механізму уваги (attention)**, що дозволив нейронним мережам ефективно працювати з даними, які можна подати у вигляді послідовності дискретних представлень: текст, зображення, аудіозаписи, відео, послідовність білкових амінокислот тощо. Механізм уваги вирішив основну проблему традиційних рекурентних мереж – неможливість ефективно враховувати контекст у довгих послідовностях. Завдяки увазі модель може зосереджуватись на найбільш важливих елементах вхідних даних, незалежно від їхньої позиції, що суттєво покращує якість розуміння контексту, коли модель приймає рішення або генерує текст.

Крім того, на відміну від рекурентних нейронних мереж, які опрацьовують послідовність поелементно, архітектура трансформера, побудована на механізмі уваги, дозволяє обробляти всі елементи вхідної послідовності одночасно. Це можна порівняти з пошуком інформації у книзі: якщо рекурентна мережа читає її слово за словом, поступово накопичуючи контекст, то трансформер «бачить» увесь текст одразу й може миттєво зосередитись на тих місцях, які найбільш важливі для поточного завдання. Такий підхід забезпечує ефективне моделювання довгострокових залежностей у послідовностях, зменшує часову складність обчислень завдяки паралельній обробці елементів вхідних даних та створює передумови для масштабування архітектури на великі набори даних.

Архітектура трансформера (Transformer) запропонована 2017 року у статті «Attention is All You Need» повністю побудована на механізмі **самоуваги (self-attention)** та позбавлена рекурентних або згорткових елементів. Архітектура трансформера стала основою для побудови сучасних генеративних моделей, зокрема **Generatively Pretrained Transformer (GPT)**. Моделі серії GPT (GPT-2, GPT-3) і, зокрема, ChatGPT, показали здатність трансформерних нейронних мереж не лише до контекстного аналізу тексту, а й до *авторегресивної генерації*[1] зв'язного та семантично узгодженого тексту. У таких моделях використовується підхід попереднього навчання на великих корпусах даних з подальшим донавчанням (*fine-tuning*) для конкретних завдань.

Мета

Отримати практичний досвід та засвоїти принцип роботи механізму уваги у трансформерних моделях, розібратись з практичною реалізацією.

[1] Модель крок за кроком прогнозує умовний розподіл наступного токена за всіма попередніми.

Навчальний матеріал

- Sebastian Raschka - Coding Attention Mechanisms
- Andrej Karpathy - Let's build GPT: from scratch, in code, spelled out. `[Colab example]`
- Grant Sanderson - Visualizing transformers and attention
- Grant Sanderson - Attention in transformers, step-by-step

Завдання

На основі запропонованих навчальних матеріалів і прикладів [2] потрібно розібратись з принципом роботи механізму уваги та трансформерів:

1. Перекладіть блокнот українською мовою[3] (Coding Attention Mechanisms) та розберіться з реалізацією механізму уваги, додавши власні пояснення до коду.
2. Підготуйте в LaTeX детальний звіт щодо реалізації механізму уваги та спрощеної моделі GPT. Опис необхідно супроводжувати формулами, рисунками та прикладами коду. У висновках резюмуйте пророблену роботу, відобразіть свої спостереження.

Оцінювання

Максимальна оцінка за виконання завдання – 10 балів.

- 40% – переклад блокнота (Coding Attention Mechanisms) українською мовою та власні пояснення до коду;
- 40% – звіт у LaTeX: теорія, формули, рисунки та приклади коду щодо принципу роботи механізму уваги та спрощеної моделі GPT;
- 20% – висновки та власні спостереження.

Шаблон для підготовки звіту: drive.google.com/drive/folders/1t2Bl7XE9RJg1ox1HYkKfDrfa3tIXWPzY?usp=sharing.

Структура шаблону для звіту:

```
...
├── code     # Директорія для файлів з кодом (для лістингу коду у звіті)
│   ├── test.py
│   └── hello.c
├── images    # Основна директорія для зображень (.pdf, .jpg, .png)
│   ├── NN_.pdf
│   └── logo-red.pdf
├── main.pdf       # Файл отриманий внаслідок компіляції main.tex
├── main.tex       # TeX  файл звіту
├── ref.bib        # Бібліографія (BibTeX)
└── report.cls    # Файл налаштування стилів звіту
```

[2] Можна також використовувати інший навчальний матеріал і приклади.
[3] При першій появі терміна подавайте український відповідник з англійським у дужках.

Здача завдання

Архів `Прізвище Ім'я_Група.zip` відправляєте на перевірку СЮДИ: https://cloud.comsys.kpi.ua/s/mfM44RBo2DRBfB3. В архів покладіть:

- перекладений українською мовою блокнот Coding Attention Mechanisms (`.ipynb`) з власними поясненнями до коду;
- програмну реалізацію базової моделі GPT з експериментами;
- Ваш звіт (.pdf файл) разом з іншими файлами LaTeX, які були використані для підготовки цього звіту

Дедлайн: 02 листопада 2026 року о 23:59